RM75 机械臂强化学习随机目标到达

Stage 1 汇报总结

UR5e 基线复现 RM75 迁移 PPO 训练与评估

汇报范围 固定起点到随机目标点的仿真到达任务

资料依据 UR5E_rl.odt zhongyu_RL.pdf 当前项目代码与训练结果

汇报日期 2026 年 9 月 30 日

当前结论 已完成 RM75 仿真环境和 PPO 训练闭环 当前任务仍是末端点到点到达

汇报结构

章节	内容
1	Stage 1 目标与完成情况
2	项目架构与代码调用关系
3	输入输出奖励与网络
4	从原始 UR5 代码到当前 RM75 系统的修改记录
5	奖励函数设计及其优化过程
6	平滑运动的实现与速度参数说明
7	PPO 与 TD3 的选择
8	训练结果与问题分析
9	结果衡量方法
10	Stage 1 局限与下一步仿真优化
附录	代码位置 运行命令和汇报问答

范围说明：本报告只覆盖 zhongyu_RL.pdf 中的 Stage 1。真机测试暂不实施；障碍物点云、ESDF、多边形表示和语义接触属于后续阶段。

1 Stage 1 目标与完成情况

Stage 1 的目标是让机械臂从固定笛卡尔起点出发，在二维桌面工作区域内接收随机目标位置，并由强化学习策略生成连续的七关节控制序列，使末端执行器进入目标点附近。当前实现完成了 UR5e 基线复现、RM75 MuJoCo 模型迁移、Gymnasium 环境、PPO 训练、模型评估和断点续训。

工作项	状态	说明
本地部署与基线复现	完成	原仓库环境、PPO 主流程和可视化逻辑已梳理并修复运行问题
UR5e 迁移到 RM75	完成	七轴 URDF、STL、MJCF、执行器、TCP 临时 site 和场景已建立
固定起点到随机目标	完成	RM75-v0 提供 28 维观测、7 维动作和随机目标采样
训练与可视化评估	完成	支持 W&B、TensorBoard、批量确定性评估和窗口演示
真机测试	本阶段暂不实施	仿真增益、TCP 和关节方向不能直接当作实机参数

本阶段完成的是点到点 reaching，不是随机物体抓取。环境没有夹爪闭合动作、物体状态、抓取保持或抬升成功判据；碰撞检测用于结束危险回合，也不等同于 Stage 2 的障碍物感知规划。

2 项目架构与代码调用关系

项目按模型资产、仿真环境、强化学习算法、评估脚本和实验结果分层。PPO 不直接修改 MuJoCo 状态，只通过 Gymnasium 的 reset 和 step 接口交换数据。环境负责把归一化动作转换为目标关节角、推进物理仿真并计算奖励。

Stage 1 训练与控制数据流



图 1 Stage 1 训练与控制数据流

文件	职责
assets/rm75/RM75.urdf	厂家 ROS 模型的项目副本，网格路径改为相对路径

文件	职责
assets/rm75/rm75_imported.xml	URDF 自动转换结果，用于比较，不直接作为训练模型
assets/rm75/rm75.xml	审核后的 RM75 动力学、执行器、限位、home 姿态和临时 TCP
assets/rm75/scene.xml	地面、灯光和相机视觉设置
env_rm75.py	任务定义、初始化、IK、控制、碰撞、奖励和渲染
Algorithms/ppo_continuous_action.py	Actor Critic、rollout、GAE、PPO 更新、日志与断点
Scripts/visualize_agent.py	加载训练权重，窗口演示或无界面批量评估
tests	模型、环境、奖励、碰撞、PPO 和 checkpoint 契约测试

2.1 运行时调用顺序

1. 训练脚本解析参数并注册 RM75-v0。
2. gym.make 创建 RM75P2PEnv，环境读取 scene.xml 和 rm75.xml，并编译 MjModel。
3. reset 清空 MjData，随机化关节初值和桌面摩擦，通过 IK 把末端放到固定起点附近。
4. Actor 读取 28 维观测并生成 7 维归一化动作。
5. 环境把动作乘以 0.02 rad 后累计到 q_target，位置执行器在 10 个物理子步内跟踪目标。
6. 环境读取新状态、距离和碰撞，返回奖励和终止标志。
7. PPO 收集 2048 步 rollout，计算 GAE 和 return，再进行小批量更新。

3 输入输出奖励与网络

3.1 输入 28 维观测

切片	维数	含义	作用
obs[0:7]	7	当前关节角 q	描述机械臂构型
obs[7:14]	7	当前关节速度 qd	让策略感知运动方向和动态状态
obs[14:21]	7	位置伺服跟踪误差 q_target - q	暴露累计控制目标，消除隐藏状态
obs[21:24]	3	末端世界坐标	给出当前位置
obs[24:27]	3	目标世界坐标	告诉策略需要到达的位置
obs[27]	1	碰撞标志	表示当前接触状态

3.2 输出 7 维关节位置参考增量

策略输出不是力矩，也不是关节速度，而是无量纲动作。环境把它转换为每个环境步的目标关节角增量，并累加到位置伺服参考值。

$$a(t) \in [-1,1]^7 \quad \Delta q(t) = 0.02\, a(t) \quad q_{target}(t+1) = \mathrm{clip}(q_{target}(t) + \Delta q(t), q_{min}, q_{max})$$

由于动作空间为 [-1,1]，单步目标变化不超过 ±0.02 rad。这个限制既统一了策略概率空间，也避免一次动作给出过大的关节跳变。

3.3 PPO Actor Critic 网络

模块	结构	说明
Actor 均值网络	28 → 64 → 64 → 7	两层 Tanh，输出高斯分布均值
策略标准差	7 个可学习 log std	受训练进度上限约束，训练动作从高斯分布采样
动作有界化	tanh 压缩	动作严格落入(-1,1)，log probability 包含变量变换修正
Critic	28 → 64 → 64 → 1	估计状态价值 V(s)，用于优势函数和 PPO 更新
初始化	正交初始化	改善网络初始尺度和训练稳定性

4 从原始 UR5 代码到当前 RM75 系统的修改记录

下表按实际迭代顺序汇总主要修改。每一项都给出文件或函数位置、修改内容、原因和结果。这里的“每一次修改”按可验证的功能批次归纳，而不是逐行罗列格式变化。

序号	修改位置	修改内容	原因	影响
1	env.py 主入口	交互模式创建环境时固定 render_mode=None，由 interactive_viewer 单独启动窗口	避免 human 渲染和交互查看器重复 launch 造成段错误	交互模式可与 target-mode 同时使用
2	PPO 入口与 sys.path	删除不存在的 UR5 包副作用导入，直接导入环境类并注册 ID	修复 ModuleNotFoundError	脚本可从项目根目录直接运行
3	env.py action_space 与 step	动作改为[-1,1]归一化，再乘 0.02 rad	策略分布单位与物理单位原来混在一起	动作概率计算和实际执行一致
4	PPO Agent	高斯采样后用 tanh 压缩，并修正 log probability；删除 ClipAction	事后裁剪会使环境动作与 PPO 记录动作不一致	保证 PPO 概率比计算正确

序号	修改位置	修改内容	原因	影响
5	env.py reset	模型只编译一次，回合重置改用 mj_resetData	原代码每回合重建 XML 模型，速度慢且随机性难管理	训练吞吐提高，模型 ID 保持不变
6	env.py reset 与 IK	先定义 start_pos，再对带噪 q0 执行 IK	IK 必须知道目标起点；噪声提供初态随机化	末端每回合回到起点附近但关节构型有扰动
7	PPO 默认参数	学习率降至 1e-4，rollout 增至 2048，更新轮数降至 5，target KL 设 0.02	原更新过强，曲线波动大	限制单批策略变化
8	PPO 日志	增加 return length success collision timeout final distance saturation 和区域成功率	只看 loss 无法判断任务是否完成	训练可诊断且可比较
9	Scripts/visualize_agent.py	修复导入；加入自动选模型、确定性动作、headless 和汇总统计	原脚本不能加载本项目环境且只适合观看	可复现评估随机目标性能
10	tools/convert_rm75_urdf.py	复制厂家 URDF 和 STL，替换 package 路径并导出基础 MJCF	MuJoCo 不能直接解析 ROS package 路径	转换流程可重复
11	rm75_imported.xml 与 rm75.xml	自动导入文件和人工审核训练文件分离	再次转换不应覆盖执行器和人工参数	模型更新可追踪
12	assets/rm75/rm75.xml	加入 7 个位置执行器、关节限位、力矩限幅、home 关键帧和 ee_site	URDF 导入结果没有可训练控制接口	形成 7 轴可控模型
13	assets/rm75/scene.xml	加入地面、灯光、视觉设置；训练桌子由环境动态加入	静态场景和任务随机量需要分离	摩擦可以由 reset 种子控制
14	env_rm75.py	建立独立 RM75P2PEnv，不覆盖 UR5 环境	UR5 为 6 轴而 RM75 为 7 轴，动力学和限位不同	两套环境可以并存
15	_build_scene_and_model	编译后核验 joint_1 至 joint_7 和对应 actuator 顺序	顺序错位会把策略动作发送到错误关节	运行时快速失败而不是静默训练错误
16	_randomize_table_friction	使用 self.rng 在 reset 时更新 geom_friction	原全局随机数不受 seed 控制；重编译模型代价高	同 seed 可复现且无需重编译
17	_check_collision	加入桌面、地面和非相邻连杆自碰撞；相邻连接接触不算碰撞	只检查桌面会漏掉机械臂自碰撞	碰撞终止含义更完整
18	Gymnasium 注册	保留 UR5-v0 并新增 RM75-v0，重复导入时不重复注册	迁移不应破坏基线	gym.make 可创建两种机械臂
19	PPO 网络维度	从环境空间动态获得输入输出维度	不能硬编码 UR5 的 19 维和 6 维	同一 PPO 代码支持 28 维 7 动作 RM75

序号	修改位置	修改内容	原因	影响
20	观测 V2	加入 q_target-q，21 维扩展为 28 维	累计位置目标原来是策略看不到的隐藏状态	状态更接近马尔可夫性
21	奖励 V2	加入超时惩罚并加强距离约束	长回合无成功时缺乏明确失败信号	试验后发现约束过强，继续进入 V3
22	奖励 V3	timeout 改 10，dist_weight 改 0.03，加入 20cm 和 10cm 一次性里程碑	V2 成功样本极少，终端成功奖励太稀疏	策略获得分阶段接近信号
23	探索 V3	标准差前 25%保持 0.30，再降至 0.12；entropy 系数为 0.0001	过早降低探索会很难首次采到成功轨迹	早期充分探索，后期动作更确定
24	目标采样	新增 uniform 和 50/25/25 hard_mixture，并记录 target_region	诊断出负 Y 和远 X 区域成功率低	可定向微调，但当前结果出现区域遗忘
25	checkpoint	区分 init-from 和 resume-from；原子保存 Agent Adam 步数参数和随机状态	纯权重不能真正续训，Ctrl+C 后也可能丢失进度	支持微调和中断恢复
26	测试体系	建立 26 项模型环境奖励 PPO 和 checkpoint 单元测试	迁移涉及维度顺序碰撞和随机性，人工观看不足以验证	当前 26 项测试全部通过

5 奖励函数设计及其优化过程

当前奖励集中定义在 env_rm75.py 的 reward_cfg，并由 _compute_reward 统一计算。step 先计算末端到目标的欧氏距离、碰撞、成功和超时，再把各分量写入 info.reward_components，便于训练诊断。

$$r(t) = 50[d(t-1) - d(t)] - 0.03d(t) - 0.01 + r_{milestone} - 75I_{collision} + 100I_{success} - 10I_{timeout}$$

式中 d 表示末端与目标的欧氏距离 I 表示条件成立时取 1

分量	当前形式	设计理由
进度奖励	$50(d_{t-1}-d_t)$	只奖励距离净减少；远离目标时为负。前进再退回的两步收益基本抵消，降低来回摆动获利的可能。
距离惩罚	$-0.03d_t$	让未产生明显进度时仍偏向靠近目标。权重保持较小，避免长回合累计距离项压过成功奖励。
时间惩罚	每步-0.01	同样成功时偏向使用更少步骤，但强度较小，不会主导策略。

分量	当前形式	设计理由
20cm 里程碑	首次进入时+5	给稀疏成功奖励增加中间学习信号；每回合只触发一次。
10cm 里程碑	首次进入时+15	越接近目标给出更强信号；来回跨越阈值不能重复领取。
碰撞惩罚	碰撞时-75	碰撞同时终止回合，明确区分不安全轨迹与普通超时。
成功奖励	d<0.05m 时+100	把进入 5cm 目标球定义为本阶段任务成功，并立即终止回合。
超时惩罚	失败到 1024 步时-10	防止长期停滞；只在未成功且未碰撞时施加，避免重复惩罚。
姿态奖励	当前权重为 0	代码接口保留，但 Stage 1 只训练位置到达，不声称已学习末端姿态。

5.1 为什么改成势函数式进度奖励

原实现使用 $10(d_{prev}-d)/\max(d,10^{-6})$。当 d 很小时，分母会把很小的距离变化放大，策略可能在目标附近通过数值波动获得异常奖励。当前实现使用 $50(d_{prev}-d)$，其累计值主要由初始距离和最终距离决定。向前 0.02m 获得约+1，随后退回 0.02m 得到约-1，因此往返本身没有持续收益。由于 PPO 使用 $\gamma=0.99$，严格数学抵消会有轻微折扣误差，但比按当前距离相除更稳定。

5.2 奖励演化

版本	关键设置	判断
原始 UR5	相对进度除以当前距离，距离权重 0.5，碰撞 10	近目标奖励可能放大，距离累计项较强
UR5 稳定修复	线性进度 50，距离 0.02，碰撞 70	先减少摆动获利和碰撞行为
RM75 V2	timeout25，距离 0.1，无里程碑	失败信号明确，但稀疏成功和强负项导致成功很少
RM75 V3 当前	timeout10，距离 0.03，里程碑 5 和 15	保留目标方向，同时提高采到成功轨迹后的可学习性

5.3 下一步怎样优化奖励

- 先不要继续改成功、碰撞和距离权重。最新实验的主要问题是目标采样失衡，而不是奖励完全无效。
- 加入轨迹平滑指标后，可小权重增加动作变化惩罚，例如 $-\lambda\Delta a \| a_t-a_{t-1} \|^2$；必须同时监控成功率，避免策略因害怕动作而停住。

- 如果目标从位置扩展为位姿，再启用姿态误差奖励；在 Stage 1 位置任务中保持 orient_weight=0。
- 每次只改一组因素，并用固定验证种子比较总体成功率、最弱区域成功率、碰撞率、步数和轨迹平滑度。

6 平滑运动的实现与速度参数说明

当前系统没有显式的轨迹规划器，也没有给 PPO 设置一个名为 joint_speed 的命令参数。运动看起来较平滑，主要来自目标关节增量限制、位置伺服器动力学、物理子步和探索噪声衰减。它是受约束的闭环响应，不是经过速度、加速度和加加速度规划后得到的严格平滑轨迹。

机制	代码位置	对平滑性的作用
动作增量限制	env_rm75.py action_scale=0.02	每 20ms 只允许目标关节角最多变化 0.02rad，避免参考值瞬间大跳
累计位置目标	step 中的 q_target	策略给增量，执行器持续追踪累计目标；未完成的跟踪不会在下一步丢失
位置伺服阻尼	rm75.xml 中的 position actuator	1 至 2 轴 kp200 kv20，3 至 4 轴 kp120 kv12，5 至 7 轴 kp40 kv4；kv 对速度产生阻尼
力矩限幅	forcerange	各轴限制为 60 60 30 30 10 10 10Nm，避免仿真执行器无限施力
物理子步	timestep=0.002s substeps=10	每个策略动作内部推进 10 次动力学积分，环境控制频率为 50Hz
速度观测	obs[7:14]=qvel	速度存在于观测，策略可以学会利用，但奖励没有直接惩罚高速
探索退火	action std schedule	训练后期随机动作减小，轨迹通常更稳定；评估默认用确定性均值动作

6.1 速度在哪里

MuJoCo 中的实际关节速度是 data.qvel，由动力学积分产生，并作为观测输入策略。当前动作并不是速度命令。按参考值计算，单步最大增量 0.02rad、环境步长 0.02s，对应目标参考值最快可连续改变约 1rad/s；这个 1rad/s 只是参考变化上限，不是机械臂真实速度限值。实际速度还受惯量、kp、kv、力矩限幅和接触影响。

因此，不能仅凭 action_scale 就声称满足实机速度安全要求。若要形成可验证的平滑轨迹，需要加入关节速度、加速度和 jerk 统计，并在环境或低层控制器中显式限制。

6.2 下一步平滑性改进

1. 在 info 和评估脚本中记录每回合 max|qd|、RMS 速度、RMS 加速度和 RMS jerk。

2. 根据厂家仿真目标值加入每轴速度和加速度限制；真机参数暂不使用。

3. 优先增加动作变化惩罚或低通滤波，再观察是否降低成功率。

4. 如需严格时间最优且平滑，可让策略输出末端或关节目标，再由独立轨迹生成器做速度规划。

7 PPO 与 TD3 的选择

比较项	PPO	TD3
策略类型	随机策略 on policy	确定性策略 off policy
数据使用	采样后更新若干轮，之后丢弃	经验回放可重复利用，样本效率通常更高
稳定机制	概率比裁剪、KL 阈值、优势标准化	双 Critic、延迟 Actor 更新、目标策略平滑
探索	策略分布标准差直接控制	确定性动作外加探索噪声
当前工程成熟度	已完成 RM75 接入、日志、测试、评估和 checkpoint	仓库有代码，但尚未完成同等 RM75 验证
Stage 1 建议	作为当前主算法	后续作为对照实验，不直接替换

选择 PPO 的直接原因是当前任务在仿真中可大量采样，PPO 更新幅度容易限制，现有训练和诊断链路已经完整。TD3 的经验回放更适合昂贵数据场景，但需要重新验证回放分布、探索噪声、Q 值过估计和 RM75 动作尺度。Stage 1 应先用 PPO 建立可靠基线，再用相同目标种子和相同评价指标做 TD3 对照。

8 训练结果与问题分析

实验	实际环境步	训练曲线	解释
RM75 初始 100 万步	999424	末段滚动成功 14% 最高 32%	碰撞和超时较多，基础策略尚不稳定
RM75 V2	约 108 万	末段滚动成功 0% 最高约 1%	超时和距离负项过强，成功奖励过于稀疏
RM75 V3	1998848	末段滚动成功 79% 碰撞 0%	奖励和探索修正后学会任务
困难区微调	499712	末段滚动成功 64% 碰撞 0%	负 Y 改善，但正 Y 发生遗忘

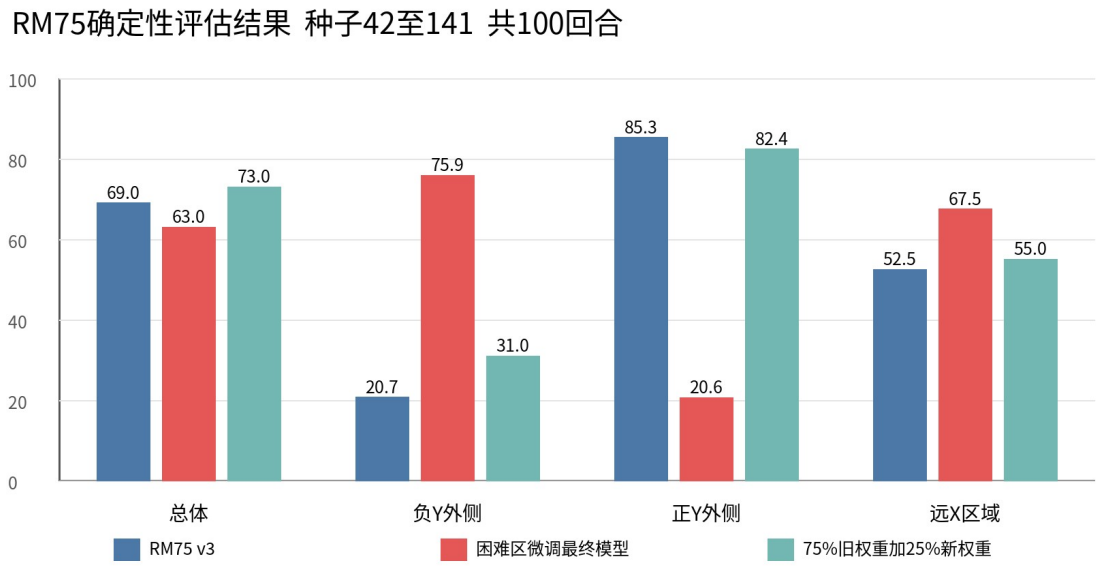


图 2 相同 100 个随机目标下的区域成功率对比

模型	成功率	碰撞率	平均最终距离	平均步数
RM75 v3	69%	0%	0.1232m	463.7
困难区微调最终模型	63%	0%	0.1134m	503.7
75%旧权重加 25%新权重	73%	0%	0.1115m	445.3

困难区微调没有整体提升，而是把能力从正 Y 区域迁移到负 Y 区域。负 Y 外侧成功率从 20.7%升至 75.9%，正 Y 外侧却从 85.3%降至 20.6%。另一组独立 100 种子也复现了这一趋势，因此主要问题是 50/25/25 采样分布导致的区域遗忘。

旧模型 75%与新模型 25%的权重插值在两组 100 种子测试中分别取得 73%和 80%，高于对应旧模型的 69%和 78%。这是有价值的候选，但尚未保存为正式模型，也需要用至少 500 个全新种子复核。

9 结果衡量方法

指标	定义	用途
成功率	成功回合数除以总回合数	核心任务指标；训练滚动值与独立评估值必须区分
分区成功率	按负 Y 正 Y 远 X 等区域统计	发现总体均值掩盖的空间盲区
碰撞率	碰撞终止回合比例	评价安全性；当前确定性评估为 0
超时率	1024 步未成功且未碰撞的比例	判断是否停滞或无法到达
最终距离	终止时末端到目标距离	失败策略是否仍在接近目标
回合步数	成功或失败前使用的环境步数	成功率相同时衡量效率

指标	定义	用途
动作饱和率	|a|>0.98 的动作比例	判断策略是否长期顶住动作边界
平滑度	RMS 速度 加速度 jerk 和动作差	当前尚未加入正式日志，是下一步补充项
PPO 诊断	KL clipfrac entropy value loss explained variance	解释更新是否过强和 Critic 预测质量，不能代替成功率

9.1 规范评估流程

1. 训练曲线用于观察学习过程，不直接当作最终性能。
2. 评估默认使用 tanh(actor_mean)确定性动作，排除训练探索噪声。
3. 使用固定且未参与调参的随机种子，至少评估 500 个目标。
4. 同时报告总体和区域指标，不只报告最好一次回合。
5. 保存模型、环境参数、代码版本和种子，使结果可以复现。

10 Stage 1 局限与下一步仿真优化

局限	当前状态	影响
临时 TCP	ee_site 位于 link_7 原点，没有真实夹爪变换	仿真点到达有效，但不能代表真实工具中心
目标只有位置	目标 z 固定，未训练姿态	不能完成需要末端朝向的抓取预备位姿
没有夹爪和物体	没有闭合、接触保持、抬升判据	不能声称完成随机点抓取
平滑性未显式优化	没有速度加速度 jerk 限制或惩罚	视觉上平滑不等于轨迹指标满足要求
碰撞信息简化	观测只有一个碰撞布尔量	策略不知道障碍方向和距离；这属于后续阶段
随机目标采样偏置	hard_mixture 过度强化负 Y	造成正 Y 能力遗忘
仿真参数来源	质量惯量采用当前 URDF，执行器增益为仿真值	不能直接映射到真机

10.1 推荐下一步

优先级	工作	建议	原因
1	改为均衡目标采样	60%全区域 15%负 Y 15%正 Y 10%远 X	维持困难区训练，同时避免左右区域遗忘
2	增加周期验证和 best model	每 5 万步在固定 200 个均匀目标上评估	最终权重不一定是训练过程中最好权重

优先级	工作	建议	原因
3	验证插值候选	至少 500 个全新种子比较旧新 插值模型	确认 73%和 80%的提升不是偶然
4	小学习率均衡微调	约 30 万步 学习率 1e-5 std 从 0.08 降至 0.06	恢复正 Y 时减少对现有能力的破坏
5	加入平滑度日志	速度 加速度 jerk 动作差	把视觉判断变成可比较的量化结果
6	保持奖励暂时不变	先隔离采样因素	避免同时改采样和奖励后无法解释结果

附录 A 关键代码位置

主题	代码位置
动作和观测空间	env_rm75.py RM75P2PEnv.__init__
模型编译与顺序检查	env_rm75.py _build_scene_and_model
初始化和 IK	env_rm75.py reset _solve_ik
动作到关节目标	env_rm75.py step _pd_to_ctrl _step_sim
奖励	env_rm75.py reward_cfg _compute_reward _compute_distance_milestone_reward
观测	env_rm75.py _get_obs
碰撞	env_rm75.py _find_robot_geom_ids _contact_pair_is_collision _check_collision
网络	Algorithms/ppo_continuous_action.py Agent
PPO 更新	Algorithms/ppo_continuous_action.py rollout GAE minibatch update
断点	save_training_checkpoint load_training_checkpoint
评估	Scripts/visualize_agent.py
模型参数	assets/rm75/rm75.xml

附录 B 可复制运行命令

B.1 完整自动测试

```
RM75_DEBUG=0 .venv/bin/python -m unittest discover -s tests -v
```

B.2 从头训练 RM75 V3

```
RM75_DEBUG=0 .venv/bin/python Algorithms/ppo_continuous_action.py \
  --env-id RM75-v0 \
  --total-timesteps 2000000 \
  --learning-rate 1e-4 \
  --track
```

B.3 批量确定性评估

```
.venv/bin/python Scripts/visualize_agent.py \
  --model-path runs/RM75-v3/ppo_continuous_action.cleanrl_model \
  --headless \
  --episodes 500 \
  --seed 20000 \
  --progress-every 0
```

B.4 窗口演示

```
.venv/bin/python Scripts/visualize_agent.py \
  --model-path runs/RM75-v3/ppo_continuous_action.cleanrl_model \
  --episodes 5
```

B.5 中断恢复

```
.venv/bin/python Algorithms/ppo_continuous_action.py \
  --resume-from runs/RUN_NAME/checkpoints/checkpoint_latest.pt
```

训练中第一次按 Ctrl+C 会完成当前 PPO 迭代后保存 checkpoint。不要使用 Ctrl+Z，Ctrl+Z 只会挂起进程。已完整结束的模型开启新一轮优化时使用--init-from，而不是--resume-from。

附录 C 老师可能追问的简短回答

问题	回答
输入是什么	28 维状态，包括关节角、关节速度、伺服跟踪误差、末端位置、目标位置和碰撞标志。
输出是什么	7 维归一化动作，经 0.02 缩放后作为每步目标关节角增量，不是力矩或速度命令。
奖励为什么这样设计	终端成功奖励定义任务，进度和里程碑解决稀疏反馈，时间项鼓励效率，碰撞和超时区分失败类型。
为什么选择 PPO	仿真可大量采样，PPO 裁剪更新稳定，当前工程链路已经完整；TD3 留作同指标对照。
速度参数在哪里	实际速度在 MuJoCo 的 qvel 中；动作是位置参考增量。0.02rad 和 50Hz 给出约 1rad/s 参考变化上限，但不是实际速度限制。
运动为什么比较平滑	小增量、位置伺服 kp kv、力矩限幅、10 个物理子步和后期低探索共同作用；当前没有显式 jerk 优化。
成功率为什么会下降	困难采样让策略重点适应负 Y，正 Y 样本不足，引起区域遗忘；不是简单的训练步数不够。
现在能不能抓取	不能。当前只验证末端点到达，没有夹爪、物体状态和抓取成功判据。

问题	回答
真机是否完成	本阶段暂不进行真机测试，仿真 TCP、增益和方向仍需后续标定。

参考资料

1. zhongyu_RL.pdf Stage 1 任务要求与汇报问题
2. UR5E_rl.odt 原始学习总结
3. UR5-Reinforcement-Learning 当前本地代码 env.py env_rm75.py PPO 与评估脚本
4. docs/superpowers/plans 中的迁移 稳定性 奖励和断点实现记录
5. runs 目录中的 TensorBoard 事件 模型权重和 checkpoint